



كلية هندسة الذكاء الاصطناعي
FACULTY OF ARTIFICIAL INTELLIGENCE ENGINEERING



English Sign Language Recognition

Junior Project

Authors: Zain Mahfouz-Ahmad al tayar-Raneem Omran

Supervised by: Dr.Majida Albakour-Eng.Farah Fares

Damascus $\frac{1447-1448}{2025-2026}$

SUPERVISOR CERTIFICATION

I certify that the preparation of this project, entitled

“English Sign Language Recognition”

prepared by

“Zain Mahfouz , Raneem Omran , Ahmad al Tayar”

was carried out under my supervision at the Faculty of Artificial Intelligence Engineering in partial fulfillment of the requirements for the degree of **B.Sc.** in the Department of Artificial Intelligence Engineering and Data Science.

Name:

Date:

Signature:

ملخص المشروع:

يستخدم الأشخاص الذين يعانون من مشكلات في السمع والنطق لغة الإشارة كوسيلة أساسية للتواصل فيما بينهم ومع الآخرين داخل المجتمع. وتعتمد هذه اللغة على مجموعة من الحركات اليدوية، والإيماءات، وتعبيرات الوجه، ووضعيات الجسد التي تشكل نظاماً لغوياً متكاملاً يعبر عن الكلمات والأفكار. وعلى الرغم من أهمية هذه اللغة، إلا أنها ليست معروفة على نطاق واسع، مما يؤدي إلى فجوة تواصلية تحد من اندماج الصم في الحياة الاجتماعية والمهنية.

ومع التطور السريع في تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، أصبح من الممكن تطوير أنظمة ذكية قادرة على تفسير لغة الإشارة وترجمتها. وتعد أنظمة التعرف على لغة الإشارة (Sign Language Recognition Systems) من أهم تطبيقات التفاعل بين الإنسان والحاسوب، حيث انتقلت من تحليل الصور الثابتة إلى تحليل مقاطع الفيديو المتسلسلة باستخدام تقنيات التعلم العميق (Deep Learning).

وفي هذا السياق، تبرز لغة الإشارة الأمريكية (ASL) كواحدة من أكثر لغات الإشارة دراسة واستخداماً عالمياً. ومع ذلك، يواجه الباحثون تحديات كبيرة في بناء نماذج قادرة على فهم الإشارات بمستوى الكلمات (Word-level) نظراً للتعقيد العالي في الحركات وتداخل الإيماءات.

قاعدة بيانات WLASL-100 المعتمدة: تم الاعتماد على نسخة مخصصة من قاعدة بيانات WLASL (World-Level American Sign Language) المتاحة عبر منصة "Kaggle"، وبالتحديد مجموعة الـ 100 فئة (WLASL-100). وتعتبر هذه القاعدة المعيار الذهبي الحالي للأبحاث، حيث تحتوي على مقاطع فيديو واقعية تم جمعها من مصادر متنوعة على الإنترنت لمؤدين مختلفين، مما يزيد من صعوبة المهمة وقيمة النتائج. تضم هذه المجموعة 100 كلمة (فئة) شائعة في لغة الإشارة الأمريكية، مما يوفر بيئة غنية لتدريب النماذج على التعرف على المفردات بدقة.

يساهم هذا العمل في دعم الجهود الرامية إلى تطوير أنظمة ترجمة تلقائية ذكية، مما يساعد على تحسين التواصل بين الأشخاص الصم وبقية أفراد المجتمع، ويعزز من فرص دمجهم في مختلف مجالات الحياة من خلال تقليل الاعتماد على المترجمين البشريين وتوفير حلول تقنية فورية.

Abstract:

People with hearing and speech impairments use sign language as their primary means of communication with each other and with others in their communities. This language relies on a set of hand movements, gestures, facial expressions, and body postures that form a complete linguistic system expressing words and ideas. Despite its importance, sign language is not widely known, leading to a communication gap that limits the social and professional integration of deaf individuals. With the rapid development of artificial intelligence and computer vision technologies, it has become possible to develop intelligent systems capable of interpreting and translating sign language. Sign language recognition systems are among the most important applications of human-computer interaction, having evolved from analyzing still images to analyzing sequential video clips using deep learning techniques. In this context, American Sign Language (ASL) stands out as one of the most studied and used sign languages globally. However, researchers face significant challenges in building models capable of understanding word-level signs due to the high complexity of the movements and the overlap of gestures. The WLASL-100 Database:

In this work, a customized version of the WLASL (World-Level American Sign Language) database available through the Kaggle platform was used, specifically the 100-category set (WLASL-100). This database is considered the current gold standard for research, as it contains real-life videos collected from various online sources featuring different performers, thus increasing the difficulty of the task and the value of the results. This set includes 100 common words (categories) in American Sign Language, providing a rich environment for training models to accurately recognize vocabulary. This work contributes to efforts to develop intelligent automatic translation systems, which help improve communication between deaf people and the rest of society and enhance their inclusion in various aspects of life by reducing reliance on human interpreters and providing immediate technological solutions.

7	فهرس الجداول
7	فهرس الأشكال
7	فهرس المعادلات
8	فهرس المصطلحات والرموز
11	الفصل الأول: تمهيد
12	1-1- مقدمة
12	1-2- المشكلة العلمية في مشروع البحث
12	1-3- هدف البحث
12	1-4- مساهمة البحث
13	1-5- الجهات المستفيدة من البحث
13	1-6- تنظيم البحث
14	الفصل الثاني: الدراسة النظرية
14	2-1- مقدمة
14	2-2- اشكال لغة الإشارة (Sign Language Recognition)
16	2-3- تقنيات رؤية الحاسوب (Computer Vision)
16	2-4- النقاط الرئيسية (Keypoints Extraction)
16	2-5- التعلم العميق (Deep Learning)
16	2-6- الشبكات العصبية الالتفافية (Convolutional Neural Networks - CNN)
18	2-7- الشبكات العصبية المتكررة (Recurrent Neural Networks - RNN)
19	2-7-1- شبكات LSTM (Long Short-Term Memory)
20	2-7-2- نموذج Bi-LSTM (Bidirectional LSTM)
22	2-8- معالجة البيانات الزمنية (Time-Series Processing)
22	2-9- خاتمة الفصل
23	الفصل الثالث: الدراسة المرجعية
23	3-1- الدراسة الأولى (2023)
23	3-2- الدراسة الثانية (2023)
24	3-3- الدراسة الثالثة (2023)
24	3-4- الدراسة الرابعة (2024)
25	3-5- الدراسة الخامسة (2023)
25	3-6- الدراسة السادسة (2023)
26	3-7- الدراسة السابعة (2023)
26	3-8- الدراسة الثامنة (2023)
26	3-9- الفجوة البحثية

27	3-10- الابتكار المقترح.....
27	3-11- خاتمة الفصل
29	الفصل الرابع: منهج البحث
30	4-1- مقدمة.....
30	4-2- نظرة عامة على مخطط النظام المقترح
30	4-3- توصيف قاعدة البيانات(Data Collection)
30	4-4- استخراج النقاط الرئيسية(Keypoints Extraction)
31	4-5- معالجة البيانات(Data Preprocessing)
31	4-6- بناء النموذج(Model Building)
32	4-7- تدريب النموذج(Model Training)
32	4-8- تقييم النموذج(Model Evaluation)
32	4-9- أدوات التنفيذ
33	4-10- خاتمة الفصل
34	الفصل الخامس: نتائج البحث
35	5-1- مقدمة.....
35	5-2- الأدوات المستعملة وأساليب التقييم المتبعة
35	5-2-1- الأدوات المستخدمة.....
35	5-2-2- معايير التقييم
36	5-3- نتائج النموذج المقترح
38	5-4- مقارنة النتائج
38	5-4-1- مقارنة نتائج النماذج المقترحة:
39	5-4-2- مقارنة النتائج مع الأعمال السابقة
40	5-5- خاتمة الفصل
42	الفصل السادس: الخاتمة
43	6-1- الاستنتاجات
43	6-2- التحديات والآفاق المستقبلية
43	6-2-1- التحديات
43	6-2-2- الآفاق المستقبلية

فهرس الجداول

8		1 TABLE: جدول المصطلحات
39		2 TABLE: جدول مقارنة النتائج للنماذج المقترحة
40		3 TABLE: جدول مقارنة نتائج النموذج المقترح مع النماذج السابقة

فهرس الأشكال

14		1 FIGURE: حركات اليد
15		2 FIGURE: وضعية الجسم
15		3 FIGURE: تعابير الوجه
16		4 FIGURE: استخراج النقاط
18		5 FIGURE: الية عمل الشبكات العصبية المتكررة
19		6 FIGURE: الية عمل شبكات LSTM
21		7 FIGURE: الية عمل شبكات Bi-LSTM
37		8 FIGURE: معمارية النموذج المقترح
37		9 FIGURE: مخطط التعلم

فهرس المعادلات

17		1 EQUATION: معادلة الالتفاف
17		2 EQUATION: دالة التفعيل
18		3 EQUATION: MAX POOLING معادلة
19		4 EQUATION: معادلة الادخال في الشبكات الصعبة المتكررة
19		5 EQUATION: معادلة الخرج في الشبكة العصبية المتكررة
19		6 EQUATION: معادلة التدرج
20		7 EQUATION: معادلة بوابة النسيان
20		8 EQUATION: معادلة بوابة الادخال
20		9 EQUATION: معادلة تحديث الذاكرة
20		10 EQUATION: معادلة بوابة الخرج
21		11 EQUATION: معادلة القراءة من البداية الى النهاية
21		12 EQUATION: معادلة القراءة من النهاية الى البداية
31		13 EQUATION: تمثيل النقاط بمجموعة احداثيات
31		14 EQUATION: تحول الاشارات الى تسلسل زمني
35		15 EQUATION: معادلة الدقة
35		16 EQUATION: معادلة الاستدعاء
36		17 EQUATION: معادلة الدقة النوعية
36		18 EQUATION: F1-SCORE مقياس

فهرس المصطلحات والرموز

Table 1: جدول المصطلحات

المصطلح	المقابل بالإنكليزية	رمز/ اختصار	معنى المصطلح
تعلم الآلة	Machine Learning	ML	مجال يهدف إلى تعليم الأنظمة من البيانات دون برمجتها صراحة.
التعلم الخاضع للإشراف	Supervised Learning	-	يتعلم من بيانات تحتوي على مدخلات ومخرجات معروفة.
التعلم غير الخاضع للإشراف	Unsupervised Learning	-	يكتشف الأنماط بدون مخرجات معروفة.
الإفراط في التعلم	Overfitting	-	عندما يتعلم النموذج التفاصيل الدقيقة لدرجة تؤثر سلباً على الأداء.
ضعف التعلم	Underfitting	-	عندما لا يلتقط النموذج الأنماط الأساسية.
تكرار التدريب	Epoch	-	مرور واحد كامل على مجموعة بيانات التدريب.
معدل التعلم	Learning Rate	-	سرعة تعديل النموذج أثناء التدريب.
دالة خسارة	Loss Function	-	معايير لمدى بُعد التنبؤات عن القيم الحقيقية.
المُحسن	Optimizer	-	خوارزمية لتقليل دالة الخسارة.
الشبكة العصبية	Neural Network	NN	بنية مستوحاة من الدماغ تُستخدم في التعلم.
التعلم العميق	Deep Learning	DL	تعلم باستخدام الشبكات العصبية العميقة.
التصنيف	Classification	-	توقع فئة معينة للبيانات.
الانحدار	Regression	-	توقع قيمة عددية مستمرة.
الدقة	Accuracy	-	نسبة التنبؤات الصحيحة إلى المجموع.

المصطلح	المقابل بالإنكليزية	رمز/ اختصار	معنى المصطلح
بانداس لمعالجة البيانات	Pandas	-	مكتبة في بايثون تساعد تنظيم البيانات
الحوسبة العددية	NumPy	-	استخدام الرياضيات والأرقام في البرمجة لحل المسائل
مكتبة الرسوم البيانية	matplotlib	-	أدوات لرسم مخططات ورسوم تساعد بفهم البيانات
التصوير الإحصائي للبيانات	Seaborn	-	مكتبة لرسم وعرض الرسوم البيانية والبيانات
-	Scikit-learn	-	مكتبة تستخدم لتدريب النماذج وتحليل البيانات
-	TensorFlow	-	مكتبة لبناء الشبكات العصبية والتعلم العميق
آلة دعم المتجهات	Support Vector Machine	SVM	خوارزمية ذكاء صناعي لتصنيف البيانات
الغابة العشوائية	Random Forest	RF	خوارزمية تعتمد على عدة أشجار لاتخاذ قرار ادق
شجرة القرار	Decision Tree	DT	طريقة لاتخاذ القرار مثل أسئلة متتالية
معامل التحديد	Coefficient of Determination	R^2	مقياس يوضح كم النموذج فهم البيانات
الجذر التربيعي لمتوسط مربع الخطأ	Root Mean Squared Error	RMSE	مقياس الأخطاء في التوقعات
الانحراف المعياري	Standard Deviation	SD	يبين هل البيانات متقاربة او متفرقة عن المتوسط
متوسط الخطأ المطلق	Mean Absolute Error	MAE	متوسط الفرق بين القيم الحقيقية والمتوقعة
متوسط مربع الخطأ	Mean Squared Error	MSE	مقياس للاخطاء

المصطلح	المقابل بالإنكليزية	رمز/ اختصار	معنى المصطلح
الدقة	Precision	-	النسبة المئوية للتوقعات الصحيحة التي قام بها النموذج
معدل الاسترجاع	Recall	-	يقيس قدرة النموذج على اكتشاف الحالات الصحيحة المهمة
درجة F1	F1-Score	-	مقياس يجمع بين الدقة والاسترجاع
مصنف التصويت	Voting Classifier	-	
التعلم التجميعي	Ensemble Learning	-	دمج عدة نماذج معا للحصول على نتيجة أقوى و أدق
خوارزميات السرب	Particle Swarm Optimization	PSO	طريقة للعثور على أفضل حل
الذاكرة طويلة قصيرة المدى	Long Short-Term Memory	LSTM	نوع مطور من RNN لديه ذاكرة أفضل
بالذاكرة طويلة قصيرة المدى ثنائية الاتجاه	Bidirectional Long Short-Term Memory	Bi-LSTM	تقرا البيانات من البداية للنهاية ومن النهاية للبداية
الشبكات العصبية الالتفافية	Convolutional Neural Networks	CNN	نموذج لتحليل الصور والفيديو
الشبكات العصبية التكرارية	Recurrent Neural Networks	RNN	نموذج يفهم البيانات المتسلسلة مثل النصوص
المُرَّمز التلقائي	Autoencoder	-	يضغط البيانات ويتعلم منها
الشبكات العصبية متعددة الطبقات	Multi-Layer Perceptron	MLP	شبكة عصبية أساسية مكونة من طبقات متعددة تستخدم للتصنيف وللتنبؤ
نماذج المحولات	Transformers	-	الأقوى في الذكاء الاصطناعي
الوحدات المكررة المبوبة	Gated Recurrent Unit	GRU	يستخدم لفهم البيانات المتسلسلة

الفصل الأول: تمهيد

12	مقدمة
12	المشكلة العلمية في مشروع البحث
12	هدف البحث
12	مساهمة البحث
13	الجهات المستفيدة من البحث
13	تنظيم البحث

1-1- مقدمة

تُعد لغة الإشارة من الوسائل الأساسية التي يعتمد عليها الأشخاص ذوو الإعاقة السمعية في التواصل مع الآخرين، حيث تعتمد على مجموعة من الحركات اليدوية وتعبير الوجه التي تشكل نظاماً لغوياً متكاملًا. وعلى الرغم من أهميتها، إلا أن استخدامها يظل محدودًا ضمن فئة معينة من المجتمع، مما يؤدي إلى وجود فجوة تواصلية واضحة بين مستخدمي هذه اللغة وبقيّة الأفراد.

مع التطور الكبير في مجالات الذكاء الاصطناعي ورؤية الحاسوب، أصبح من الممكن تطوير أنظمة ذكية قادرة على تحليل الإشارات الحركية وفهمها بشكل آلي. وقد ساهمت تقنيات التعلم العميق بشكل خاص في تحسين قدرة هذه الأنظمة على التعامل مع البيانات المعقدة، مثل البيانات الزمنية الناتجة عن تسلسل الحركات.

في هذا السياق، يركز هذا المشروع على تطوير نموذج يعتمد على التعلم العميق للتعرف على إشارات اليد باستخدام بيانات مستخرجة من مقاطع فيديو، بهدف المساهمة في تقليل الفجوة التواصلية وتحسين دمج الأشخاص الصم في المجتمع.

1-2- المشكلة العلمية في مشروع البحث

تكمن المشكلة الأساسية في صعوبة تفسير الإشارات الحركية بشكل دقيق، نظرًا لطبيعتها الزمنية وتعقيدها، حيث تتداخل الحركات وتتغير بسرعة. بالإضافة إلى ذلك، فإن الأنظمة الحالية تعاني من عدة تحديات، منها:

- محدودية الدقة في التعرف على الإشارات
- صعوبة التعامل مع البيانات الزمنية الطويلة
- الحاجة إلى نماذج قادرة على فهم السياق الكامل للحركة

بناءً على ذلك، تظهر الحاجة إلى تطوير نموذج قادر على تحليل تسلسل الإشارات بشكل أكثر كفاءة ودقة.

1-3- هدف البحث

1-1-3- الهدف الرئيسي:

بناء وتصميم نظام ذكي قادر على التعرف على إشارات اليد اعتمادًا على تقنيات التعلم العميق.

1-2-3- الأهداف الفرعية:

- تحسين دقة التعرف على الإشارات
- بناء نموذج قادر على تحليل البيانات الزمنية بكفاءة
- تقليل زمن الاستجابة أثناء التنبؤ
- توفير نموذج قابل للتطوير والتطبيق العملي

1-4- مساهمة البحث

تتمثل مساهمة هذا البحث في:

- استخدام نموذج Bi-LSTM لمعالجة البيانات الزمنية الخاصة بالإشارات
- بناء Pipeline متكامل لمعالجة البيانات بدءًا من استخراج النقاط وانتهاءً بالتصنيف
- تحسين فهم الإشارات من خلال تحليلها في اتجاهين (أمامي وخلفي)
- تقديم نموذج يمكن تطويره لاحقًا لتطبيقات عملية

1-5- الجهات المستفيدة من البحث

يمكن أن تستفيد عدة جهات من هذا المشروع، منها:

- الأشخاص ذوو الإعاقة السمعية
- الأشخاص العاديين
- المؤسسات التعليمية
- مراكز الأبحاث في الذكاء الاصطناعي
- مطورو التطبيقات الذكية

1-6- تنظيم البحث

تم تنظيم هذا البحث على الشكل التالي:

- الفصل الأول -- تمهيدًا عامًا حول موضوع البحث
- الفصل الثاني -- الأسس النظرية والتقنيات المستخدمة
- الفصل الثالث -- الدراسات السابقة وتحليلها
- الفصل الرابع -- منهجية العمل والنموذج المقترح
- الفصل الخامس -- النتائج والتقييم
- الفصل السادس -- البحث بالاستنتاجات والتوصيات المستقبلية

الفصل الثاني: الدراسة النظرية

2-1- مقدمة

يستند مشرونا على مجموعة من المفاهيم والتقنيات الأساسية في مجالات الذكاء الاصطناعي، والتعلم العميق، ورؤية الحاسوب، حيث يتم توظيف هذه المجالات معاً لبناء نظام قادر على فهم وتحليل الإشارات الحركية. ونظراً للطبيعة الزمنية المعقدة للبيانات المستخدمة في هذا النوع من التطبيقات، فإن اختيار النماذج والخوارزميات المناسبة يُعد عنصراً حاسماً في تحقيق أداء دقيق وموثوق.

في هذا الفصل، سيتم عرض الأسس النظرية التي يعتمد عليها المشروع، بدءاً من التعرف على لغة الإشارة، مروراً بمفاهيم التعلم العميق، وصولاً إلى النماذج المستخدمة في معالجة البيانات الزمنية.

2-2- اشكال لغة الإشارة (Sign Language Recognition)

يُعرف التعرف على لغة الإشارة بأنه عملية تحليل الإشارات الحركية وتحويلها إلى تمثيل مفهوم، مثل نص أو صوت. وتعتمد هذه العملية على تفسير مجموعة من العناصر، منها:

- حركات اليد :



• وضعية الجسم :




Figure 2: وضعية الجسم

• تعابير الوجه :




Figure 3: تعابير الوجه

3-2- أنظمة لغة الإشارة:

وتنقسم أنظمة التعرف على لغة الإشارة إلى نوعين رئيسيين:

- أنظمة تعتمد على الصور الثابتة: تقوم بتحليل كل صورة بشكل منفصل، وتناسب الحالات البسيطة.
- أنظمة تعتمد على الفيديو (التسلسل الزمني): تقوم بتحليل سلسلة من الإطارات، وهي الأكثر دقة نظرًا لقدرتها على فهم تطور الحركة عبر الزمن.

ويُعد هذا المشروع من النوع الثاني، حيث يعتمد على تحليل تسلسل زمني للحركات.

2-3- تقنيات رؤية الحاسوب (Computer Vision)

تُعد رؤية الحاسوب أحد الفروع الأساسية في الذكاء الاصطناعي، وتهدف إلى تمكين الحاسوب من فهم وتحليل الصور والفيديوهات بطريقة مشابهة للرؤية البشرية. وفي سياق هذا المشروع، يتم استخدام تقنيات رؤية الحاسوب لاستخراج المعلومات المهمة من الفيديو، مثل:

- تحديد مواقع اليد: لعدم تشتيت النموذج بالعناصر المحيطة في الفيديو
- استخراج النقاط الرئيسية (Keypoints): تحويل الهيكل الحركي لليد والجسم من بكسلات وصور خام إلى تمثيل رياضي وهندسي
- تتبع الحركة عبر الزمن: من خلال ربط السلاسل الزمنية عبر طبقات الشبكات العصبية ثنائية الاتجاه

وتُحول هذه البيانات لاحقاً إلى تمثيل رقمي يمكن استخدامه في تدريب النماذج.

2-4- النقاط الرئيسية (Keypoints Extraction)

تعتمد العديد من أنظمة التعرف على الإشارات على استخراج النقاط الرئيسية من جسم الإنسان، وخاصة اليدين. وتمثل هذه النقاط إحداثيات مفاصل معينة، مثل:

- مفاصل الأصابع
- المعصم
- أجزاء من الذراع

ويتم تمثيل كل نقطة بإحداثيات (x, y) أو (x, y, z) ، مما يسمح بتحويل الحركة إلى بيانات رقمية منظمة.

تُستخدم هذه الطريقة لأنها:

- تقلل من حجم البيانات مقارنة بالفيديو الكامل
- تركز على المعلومات المهمة فقط
- تسهل عملية التدريب للنماذج

2-5- التعلم العميق (Deep Learning)

يُعتبر التعلم العميق أحد فروع تعلم الآلة، ويعتمد على الشبكات العصبية الاصطناعية ذات الطبقات المتعددة. ويتميز بقدرته على استخراج الأنماط المعقدة من البيانات دون الحاجة إلى تدخل بشري كبير.

في هذا المشروع، يتم استخدام التعلم العميق لتحليل البيانات الزمنية الناتجة عن تسلسل الإشارات، حيث يقوم النموذج بتعلم العلاقات بين الحركات المختلفة من أجل تصنيفها بشكل صحيح.

2-6- الشبكات العصبية الالتفافية (Convolutional Neural Networks - CNN)

تُعد الشبكات العصبية الالتفافية (CNN) من أكثر نماذج التعلم العميق استخدامًا في مجال معالجة الصور ورؤية الحاسوب، حيث تتميز بقدرتها العالية على استخراج الخصائص المهمة من الصور بشكل تلقائي دون الحاجة إلى تحديدها يدويًا. تعتمد CNN على تطبيق عمليات رياضية تُعرف باسم الالتفاف (Convolution)، والتي تسمح باستخراج الأنماط المهمة مثل الحواف، الأشكال، والحركات

-يشير الشكل 4 إلى بنية CNN




Figure4: آلية عمل الشبكات العصبية الالتفافية

تتكون بنية CNN عادةً من عدة طبقات رئيسية، وهي:

- طبقة الالتفاف (Convolution Layer)
- طبقة التنفيل (Activation Layer)
- طبقة التجميع (Pooling Layer)
- الطبقات كاملة الاتصال (Fully Connected Layers)

2-6-آلية العمل

تقوم طبقة الالتفاف بتطبيق مرشح (Filter) أو نواة (Kernel) على الصورة لاستخراج الخصائص المهمة. يمكن التعبير عن عملية الالتفاف رياضياً كما يلي:

Equation 1: معادلة الالتفاف

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i - m, j - n) K(m, n) \quad (2/1)$$

حيث:

- I : الصورة الأصلية
- k : المرشح (Kernel)
- $S(i, j)$: ناتج عملية الالتفاف

بعد ذلك يتم تمرير الناتج إلى دالة التنفيل (Activation Function)، وغالبًا يتم استخدام دالة ReLU:

Equation 2: دالة التنفيل

$$f(x) = \max(0, x) \quad (2/2)$$

تساعد هذه الدالة على إدخال اللاخطية إلى النموذج وتحسين قدرته على تعلم الأنماط المعقدة.

طبقة التجميع (Pooling Layer)

تُستخدم طبقة التجميع لتقليل أبعاد البيانات مع الحفاظ على المعلومات المهمة، مما يساعد على تقليل التعقيد الحسابي.

ويُعد Max Pooling من أكثر الأنواع استخدامًا:

Max Pooling معادلة 3: Equation

$$(2/3) \quad P(i, j) = \max_{\{(m,n) \in R\} S(m,n)}$$

حيث تمثل R منطقة التجميع.

مميزات CNN


- القدرة على استخراج الخصائص تلقائيًا
- فعالية عالية في معالجة الصور
- تقليل الحاجة إلى المعالجة اليدوية للبيانات
- تحقيق دقة مرتفعة في تطبيقات رؤية الحاسوب

العيوب

- تحتاج إلى بيانات كبيرة نسبيًا
- أدائها ينخفض عند معالجة العلاقات الزمنية وحدها دون نماذج تسلسلية

2-7- الشبكات العصبية المتكررة (Recurrent Neural Networks - RNN)

تم تصميم الشبكات العصبية المتكررة للتعامل مع البيانات المتسلسلة، حيث تأخذ بعين الاعتبار ترتيب البيانات واعتماد عتمد



هذه الشبكات على مفهوم الحالة المخفية (Hidden State) ، والتي تمثل ذاكرة داخلية يتم تحديثها في كل خطوة زمنية بناءً على المدخل الحالي والحالة السابقة.

يمكن التعبير عن آلية عمل الشبكة رياضياً كما يلي:

Equation 4: معادلة الادخال في الشبكات العصبية المتكررة

$$(2/4) \quad h_t = f(W_h h_{t-1} + W_x x_t + b)$$

حيث تمثل h_t الحالة الحالية، و x_t المدخل عن الزمن t ، بينما تمثل W_x و W_h الاوزان.

اما خرج الشبكة يحسب كالتالي:

Equation 5: معادلة الخرج في الشبكة العصبية المتكررة

$$(2/5) \quad y_t = W_y h_t$$

تسمح هذه البنية للشبكة بنقل المعلومات عبر الزمن، مما يجعلها مناسبة لمعالجة:

- النصوص
- الإشارات الزمنية
- الفيديوهات

إلا أنها تعاني من مشكلة تُعرف بتلاشي التدرج (Vanishing Gradient)، التي تحدث أثناء التدريب نتيجة تكرار ضرب المشتقات:


Equation 6: معادلة التدرج

$$(2/6) \quad \frac{\partial L}{\partial h_t} = \prod_{k=1}^t \frac{\partial h_k}{\partial h_{k-1}}$$

حيث يؤدي ذلك إلى صعوبة تعلم العلاقات طوي المدى.

2-7-1 شبكات LSTM (Long Short-Term Memory)

تم تطوير شبكات LSTM كحل لمشاكل الشبكات المتكررة التقليدية، حيث تتميز بقدرتها على الاحتفاظ بالمعلومات لفترات زمنية طويلة، ويشير الشكل 5 إلى بنية Lstm



الشكل -5-

تعتمد LSTM على بنية داخلية تتكون من ثلاث بوابات رئيسية:

- **بوابة النسيان (Forget Gate):** تحدد المعلومات التي يجب الاحتفاظ بها أو حذفها من الذاكرة السابقة:

Equation 7: معادلة بوابة النسيان

$$(2/7) \quad f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

- **بوابة الإدخال (Input Gate):** تحدد المعلومات الجديدة التي سيتم إضافتها إلى الذاكرة:

Equation 8: معادلة بوابة الإدخال

$$(2/8) \quad i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

- **تحديث الذاكرة**

يتم دمج المعلومات القديمة مع الجديدة وفق العلاقة:

Equation 9: معادلة تحديث الذاكرة

$$(2/9) \quad C_t = f_t C_{t-1} + \tilde{i}_t \{C\}_t$$

- **بوابة الإخراج (Output Gate):** تحدد المعلومات التي سيتم تمريرها إلى الخارج:

Equation 10: معادلة بوابة الإخراج

$$(2/10) \quad h_t = o_t \tanh(C_t)$$

النية العمل:

تعمل LSTM على تمرير المعلومات المهمة عبر الزمن باستخدام حالة الخلية C_t ، حيث يتم الحفاظ على المعلومات ذات القيمة العالية، والتخلص من المعلومات غير المهمة.


هذه الآلية تساعد في:

- التغلب على مشكلة تلاشي التدرج
- تحسين القدرة على تعلم العلاقات طويلة المدى
- زيادة دقة النماذج في المهام الزمنية

2-7-2- نموذج Bi-LSTM (Bidirectional LSTM)

يُعد نموذج Bi-LSTM تطويرًا لنموذج LSTM، حيث يقوم بمعالجة البيانات في اتجاهين:

- من البداية إلى النهاية (Forward Pass)
- من النهاية إلى البداية (Backward Pass)



الشكل -6-

ثم يتم دمج النتائج للحصول على تمثيل أكثر شمولاً للسلسلة الزمنية, ويشير الشكل 6 الى بنية Bi-lstm المعادلات الرياضية:

يتم حساب الحالتين كالتالي:

Equation 11: معادلة القراءة من البداية الى النهاية

$$(2/ 11) \quad h_t^{\rightarrow} = LSTM(x_t, h_{\{t-1\}}^{\rightarrow})$$

Equation 12: معادلة القراءة من النهاية الى البداية

$$(2/ 12) \quad h_t^{\leftarrow} = LSTM(x_t, h_{\{t-1\}}^{\leftarrow})$$

ثم يتم دمجها:

$$(2/ 13) \quad h_t = [h_t^{\rightarrow}; h_t^{\leftarrow}]$$

الية العمل

يقوم النموذج بتحليل التسلسل من جهتين:

- الاتجاه الأمامي يساعد على فهم السياق السابق
- الاتجاه العكسي يساعد على فهم السياق اللاحق

ثم يتم دمج المعلومات للحصول على تمثيل غني للسلسلة الزمنية.

تكمن أهمية هذا النموذج في أنه:

- يأخذ بعين الاعتبار الماضي والمستقبل
- يحسن دقة التنبؤ
- مناسب جدًا لتحليل الإشارات الحركية

ولذلك تم اعتماده كنموذج أساسي في هذا المشروع.

2-8- معالجة البيانات الزمنية (Time-Series Processing)

تُعد البيانات المستخدمة في هذا المشروع من نوع البيانات الزمنية، حيث تمثل كل إشارة سلسلة من القيم المرتبة زمنيًا. ويتطلب التعامل مع هذا النوع من البيانات:

- الحفاظ على ترتيب القيم
- فهم العلاقة بين النقاط المتتالية
- التعامل مع اختلاف طول التسلسلات

ويتم تجهيز هذه البيانات قبل إدخالها إلى النموذج من خلال:

- توحيد طول التسلسلات
- تنظيف البيانات
- تنظيمها ضمن مصفوفات مناسبة للتدريب

2-9- خاتمة الفصل

تم في هذا الفصل استعراض المفاهيم النظرية الأساسية التي يعتمد عليها هذا البحث، بدءًا من التعرف على لغة الإشارة، مرورًا برؤية الحاسوب واستخراج النقاط الرئيسية، وصولًا إلى نماذج التعلم العميق المستخدمة في تحليل البيانات الزمنية.

تشكل هذه الأسس قاعدة علمية متينة سيتم الاعتماد عليها في الفصل التالي، الذي يتناول الدراسات السابقة وتحليل الأعمال المتعلقة بهذا المجال، بهدف تحديد الفجوة البحثية وبناء الحل المقتر.

الفصل الثالث: الدراسة المرجعية

3-1- الدراسة الأولى (2023)

دراسة بعنوان:

“Sign Language Recognition from Digital Videos using Feature Pyramid Network with Detection Transformer”

- **المساهمة:** استخدام Feature Pyramid مع Transformer لتحسين استخراج الميزات المكانية والزمنية .
- **الموديل:** CNN + Detection Transformer .
- **البيانات:** فيديوها لغة الإشارة .
- **استخراج الميزات: (Feature Extraction)**
تم استخدام شبكات CNN لاستخراج الخصائص المكانية من إطارات الفيديو، بينما عملت Feature Pyramid Network (FPN) على دمج الميزات متعددة المستويات لتحسين تمثيل الحركة. بعد ذلك استخدم Detection Transformer لتحليل التسلسل الزمني للحركات .
- **معالجة البيانات:**
تم تقسيم الفيديو إلى إطارات (Frames) ، ثم إعادة تحجيم الصور وتطبيعها (Normalization) ، مع تطبيق Data Augmentation مثل التدوير والقص لتحسين قدرة النموذج على التعميم .
- **معايير التقييم:**
F1-Score. ، Recall ، Precision ، Accuracy
- **النتائج :**
 - Accuracy: 91.3%
 - Precision: 90.8%
 - Recall: 89.7%
 - F1-Score: 90.2%
- **نقاط القوة:** دمج فعال بين المعلومات المكانية والزمنية .
- **نقاط الضعف:** تعقيد عالي في التدريب واستهلاك الموارد .

3-2- الدراسة الثانية (2023)

دراسة بعنوان:

“Sign2Pose: A Pose-Based Approach for Gloss Prediction Using a Transformer Model”

- **المساهمة:** استخدام Keypoints بدل الفيديو الكامل .
- **الموديل:** Transformer .
- **البيانات:** تمثيل هيكل الحركة .
- **استخراج الميزات:**
تم استخراج نقاط المفاصل (Keypoints) باستخدام تقنيات Human Pose Estimation مثل MediaPipe أو OpenPose ، ثم تحويلها إلى متجهات تمثل حركة الجسم واليدين .
- **معالجة البيانات:**
تم تنظيف البيانات الناقصة، وتوحيد الإحداثيات، وتطبيع قيم النقاط لتقليل تأثير اختلاف المسافات والزوايا بين الأشخاص .
- **معايير التقييم:**
F1-Score. ، Accuracy
- **النتائج :**
 - Accuracy: 89.6%

F1-Score: 88.9% ○

- نقاط القوة: تقليل حجم البيانات وزيادة الكفاءة .
- نقاط الضعف: يعتمد بشكل كبير على دقة استخراج النقاط .

3-3 الدراسة الثالثة (2023)

دراسة بعنوان:

“Modelling Sign Language with Encoder-Only Transformers and Human Pose Estimation Keypoint Data”

- المساهمة: استخدام Keypoints مع Transformer.
- الموديل: Encoder-only Transformer.
- البيانات: WLASL Dataset.
- استخراج الميزات:
- تم استخراج Keypoints الخاصة بالجسم واليدين والوجه من الفيديو وتحويلها إلى تسلسلات زمنية يتم إدخالها إلى Transformer Encoder.
- معالجة البيانات:
- شملت إزالة الضوضاء، وتوحيد طول التسلسلات الزمنية، وتطبيع الإحداثيات قبل التدريب .
- معايير التقييم:
- Loss, Accuracy.
- النتائج :
- Accuracy: 90.4%
- Loss: منخفض ومستقر أثناء التدريب .
- نقاط القوة: مناسبة للبيانات المشابهة لمشروعك .
- نقاط الضعف: تحتاج تدريب مكثف ووقت طويل .

3-4 الدراسة الرابعة (2024)

دراسة بعنوان:

“Skeletal-Coordinate-Based Sign Language Recognition using Transformer Encoders”

- المساهمة: استخدام تمثيل الهيكل العظمي .
- الموديل: Multiple Transformer Encoders.
- استخراج الميزات:
- تم الاعتماد على الإحداثيات الهيكلية للمفاصل (Skeletal Coordinates) واستخراج العلاقات المكانية والزمنية بينها باستخدام عدة Transformer Encoders.
- معالجة البيانات:
- تم تحويل الحركات إلى تسلسلات هيكلية، مع تطبيق Normalization للإحداثيات وتقليل الضوضاء الناتجة عن أخطاء التتبع .
- معايير التقييم:
- Recall, Precision, Accuracy.
- النتائج :
- Accuracy: 92.1%

- Precision: 91.5% ○
- Recall: 90.9% ○
- نقاط القوة: فهم أفضل للعلاقات بين المفاصل .
- نقاط الضعف: تعقيد في بناء النموذج .

3-5 الدراسة الخامسة (2023)

دراسة بعنوان:

“Self-Supervised Video Transformers for Isolated Sign Language Recognition”

- المساهمة: استخدام التعلم الذاتي (Self-Supervised Learning).
- الموديل: Video Transformer.
- استخراج الميزات:
- تم استخراج الميزات مباشرة من الفيديو باستخدام Video Transformer دون الحاجة إلى استخراج يدوي للخصائص .
- معالجة البيانات:
- تم استخدام مقاطع فيديو غير معنونة جزئيًا، مع تقسيم الفيديو إلى Clips وتطبيق Augmentation مثل تغيير السرعة والقص العشوائي .
- معايير التقييم:
- F1-Score. ،Accuracy
- النتائج :
- Accuracy: 93.5% ○
- F1-Score: 92.8% ○
- نقاط القوة: لا تحتاج بيانات مصنفة بالكامل .
- نقاط الضعف: تحتاج موارد حاسوبية كبيرة .

3-6 الدراسة السادسة (2023)

دراسة بعنوان:

“Human Part-wise 3D Motion Context Learning for Sign Language Recognition (P3D)”

- المساهمة: تحليل الحركة لكل جزء من الجسم .
- الموديل: Transformer + 2D/3D Pose .
- استخراج الميزات:
- تم استخراج حركات الجسم ثلاثية الأبعاد (3D Pose) وثنائية الأبعاد (2D Pose) وتحليلها لكل جزء من أجزاء الجسم بشكل منفصل .
- معالجة البيانات:
- تم دمج بيانات الحركة من عدة زوايا، مع معالجة الإطارات المفقودة وتوحيد التسلسلات الزمنية .
- معايير التقييم:
- Recall. ،Accuracy
- النتائج :
- Accuracy: 94.2% ○
- Recall: 93.6% ○
- نقاط القوة: دقة عالية جدًا .

- نقاط الضعف: معقد جدًا وصعب التطبيق .

3-7 الدراسة السابعة (2023)

دراسة بعنوان:

“SignGraph: A Pose-Based Graph Convolution Approach”

- المساهمة: استخدام Graph Neural Networks.
- الموديل GCN.
- استخراج الميزات:
- تم تحويل نقاط المفاصل إلى Graph Structure بحيث تمثل المفاصل عقدًا (Nodes) والعلاقات بينها حوافًا (Edges).
- معالجة البيانات:
- تم استخراج Keypoints أولاً ثم بناء الرسم البياني للحركة مع تطبيق تطبيع للإحداثيات .
- معايير التقييم:
- F1-Score. ، Accuracy
- النتائج :
- Accuracy: 90.7% ○
- F1-Score: 90.1% ○
- نقاط القوة: فهم العلاقات بين المفاصل .
- نقاط الضعف: صعوبة التدريب .

3-8 الدراسة الثامنة (2023)

دراسة بعنوان:

“MIPA-ResGCN: Graph Convolution Framework for Sign Language Recognition”

- المساهمة: تحسين GNN باستخدام Attention.
- الموديل ResGCN + Attention.
- استخراج الميزات:
- تم استخراج Keypoints ثم استخدام ResGCN لاستخراج العلاقات المكانية، بينما ساعدت آلية Attention في التركيز على الحركات المهمة .
- معالجة البيانات:
- تضمنت إزالة الضوضاء، وتوحيد الإحداثيات، وتقسيم الحركات إلى تسلسلات زمنية قابلة للتحليل .
- معايير التقييم:
- Precision. ، Accuracy
- النتائج :
- Accuracy: 91.8% ○
- Precision: 91.2% ○
- نقاط القوة: تحسين الأداء مع تقليل التعقيد .
- نقاط الضعف: ما زالت معقدة مقارنة ب LSTM.

3-9 الفجوة البحثية

من خلال تحليل الدراسات السابقة، يمكن استخلاص ما يلي:

- النماذج الحديثة (Transformers) تحقق دقة عالية تتجاوز 90 % لكنها تحتاج موارد كبيرة جدًا
- النماذج التقليدية (LSTM) أبسط لكنها أقل قدرة على فهم السياق الكامل
- استخدام Keypoints أثبت فعاليته، لكنه يحتاج نموذج مناسب لتحليل التسلسل

3-10- الابتكار المقترح

بناءً على التحليل السابق للدراسات الحديثة في مجال التعرف على لغة الإشارة، يمكن ملاحظة أن معظم النماذج المتقدمة، وخاصة المعتمدة على Transformer و Graph Neural Networks، تحقق دقة عالية، إلا أنها تتطلب موارد حاسوبية كبيرة، بالإضافة إلى الحاجة إلى بيانات ضخمة ومتنوعة.

في المقابل، فإن النماذج التقليدية مثل LSTM تمتاز بالبساطة والكفاءة، لكنها تعاني من محدودية في فهم السياق الزمني الكامل للإشارات.

انطلاقاً من ذلك، يقترح هذا البحث تطوير نموذج يعتمد على دمج تمثيل البيانات باستخدام Keypoints مع نموذج Bi-LSTM، وذلك لتحقيق توازن فعال بين الدقة والكفاءة.

تعتمد فكرة الابتكار المقترح على النقاط التالية:

- استخدام Keypoints بدلاً من الفيديو الكامل، مما يؤدي إلى تقليل حجم البيانات بشكل كبير، وبالتالي تسريع عملية التدريب وتقليل استهلاك الموارد.
- الاستفادة من نموذج Bi-LSTM لتحليل التسلسل الزمني للإشارات في اتجاهين، مما يسمح بفهم أفضل للحركات مقارنةً بالنماذج أحادية الاتجاه.
- بناء Pipeline له دخل عبارة عن فيديو والخرج عبارة عن كلمة، وهو متكامل يشمل مراحل استخراج البيانات، المعالجة المسبقة، التدريب، والتقييم، لضمان الحصول على نتائج مستقرة وقابلة للتكرار.
- تحقيق توازن بين الأداء والدقة، بحيث يكون النموذج مناسباً للتطبيقات العملية، وخاصة في البيئات ذات الموارد المحدودة.

كما يتميز النموذج المقترح بإمكانية تطويره مستقبلاً، من خلال دمج مع تقنيات أخرى مثل Attention Mechanism أو تحسين طرق تمثيل البيانات.

3-11- خاتمة الفصل

تم في هذا الفصل استعراض وتحليل مجموعة من الدراسات الحديثة في مجال التعرف على لغة الإشارة، مع التركيز على النماذج المستخدمة، وأنواع البيانات، ومعايير التقييم، والنتائج التي تم تحقيقها.

أظهر التحليل أن هناك اتجاهًا واضحًا نحو استخدام النماذج المتقدمة مثل Transformer و Graph Neural Networks، والتي تحقق دقة عالية، إلا أنها تتطلب موارد حاسوبية كبيرة وتعقيدًا في التنفيذ. في المقابل، توفر النماذج الزمنية مثل LSTM و Bi-LSTM حلاً أكثر توازنًا من حيث الكفاءة وسهولة التطبيق.

كما تبين أن استخدام تمثيل البيانات باستخدام Keypoints يعد خيارًا فعالًا لتقليل التعقيد مع الحفاظ على جودة الأداء، خاصة عند دمجها مع نماذج قادرة على معالجة التسلسل الزمني.

بناءً على ذلك، تم اقتراح نموذج يعتمد على Bi-LSTM لمعالجة بيانات Keypoints، بهدف تحقيق أداء جيد مع تقليل التعقيد الحسابي، وهو ما سيتم تناوله بالتفصيل في الفصل التالي من خلال عرض منهجية البحث والنموذج المقترح.

الفصل الرابع: منهج البحث

30	 نظرة عامة على النظام المقترح.
30	 جمع البيانات (Data Collection)
30	 استخراج النقاط الرئيسية (Keypoints Extraction)
31	 معالجة البيانات (Data Preprocessing)
31	 بناء النموذج (Model Building)
32	 تدريب النموذج (Model Training)
32	 تقييم النموذج (Model Evaluation)
32	 أدوات التنفيذ
33	 خاتمة الفصل

4-1- مقدمة

يهدف هذا الفصل إلى عرض المنهجية المتبعة في تطوير نظام التعرف على لغة الإشارة، بدءًا من جمع البيانات ومعالجتها، وصولًا إلى تصميم النموذج وتدريبه وتقييمه. تم اعتماد منهجية منظمة تعتمد على تحويل الإشارات الحركية إلى تمثيل رقمي باستخدام النقاط الرئيسية (Keypoints)، ومن ثم معالجة هذه البيانات باستخدام نموذج زمني قادر على فهم تسلسل الحركات. تم اختيار هذه المنهجية بهدف تحقيق توازن بين الدقة والكفاءة، مع تقليل التعقيد الحسابي مقارنة بالنماذج الحديثة ذات المتطلبات العالية.

4-2- نظرة عامة على مخطط النظام المقترح

يتكون النظام المقترح من مجموعة من المراحل المتتالية، يمكن تلخيصها كما يلي :

1. توصيف قاعدة البيانات: بيانات 80 فيديو بعد استخدام agumentaion كل فيديو (30 frame) تحتوي على إشارات يدوية تمثل كلمات (100 كلمة كل كلمة لديها من 9 إلى 10 فيديوهات)
2. معالجة البيانات (data proccesing): تمت معالجة مشكلة ان ابعاد الفيديو مختلفة عن طريق جعل الانف مركز الوجه، وتم تطبيق agumentation على الفيديوهات
3. استخراج النقاط الرئيسية (Keypoints Extraction) : وهي نقاط مفاصل الأصابع و المعصم واجزاء من الذراع وفي الوجه جعلنا الانف مركز الاحداثيات
4. بناء النموذج (Model Building) : باستخدام اكثر من مودل وهم Bi-lstm و Lstm و Cnn
5. تدريب النموذج (Training)
6. تقييم الأداء (Evaluation) : باستخدام F1-score و Accuracy

تشكل هذه المراحل ما يُعرف بـ Pipeline متكامل يهدف إلى ضمان الحصول على نتائج دقيقة ومستقرة.

4-3- توصيف قاعدة البيانات (Data Collection)

تم الاعتماد على بيانات 80 فيديو كل فيديو (30 frame) تحتوي على إشارات يدوية تمثل كلمات (100 كلمة كل كلمة لديها من 9 إلى 10 فيديوهات) أو عبارات محددة. وقد تم اختيار البيانات بحيث تشمل تنوعًا في:

- زوايا التصوير
- سرعة الحركة
- شكل اليد
- الخلفية

وذلك بهدف زيادة قدرة النموذج على التعميم وتقليل تأثير العوامل الخارجية.

4-4- استخراج النقاط الرئيسية (Keypoints Extraction)

تم استخدام تقنيات رؤية الحاسوب لاستخراج النقاط الرئيسية التي تمثل مفاصل اليد والجسم، حيث يتم تمثيل كل إطار بمجموعة من الإحداثيات الثنائية:

Equation 13: تمثيل النقاط بمجموعة احداثيات

$$(1/4) P_i = (x_i, y_i) P_i = (x_i, y_i) P_i = (x_i, y_i)$$

وبذلك تتحول كل إشارة إلى تسلسل زمني من النقاط:

Equation 14: تحول الاشارات الى تسلسل زمني

$$(2/4) S = \{P_1, P_2, \dots, P_T\} S = \{P_1, P_2, \dots, P_T\} S = \{P_1, P_2, \dots, P_T\}$$

هذا التمثيل يسمح بتقليل حجم البيانات مقارنة بالفيديو الكامل، مع الحفاظ على المعلومات الحركية الأساسية.

4-5- معالجة البيانات (Data Preprocessing)

تُعد مرحلة معالجة البيانات من أهم مراحل بناء النظام، حيث تؤثر بشكل مباشر على أداء النموذج. وقد تضمنت هذه المرحلة ما يلي:

- تنظيف البيانات: إزالة القيم غير الصالحة أو المفقودة
- توحيد طول التسلسلات: باستخدام padding أو trimming
- تطبيع البيانات: (Normalization) لتقليل تأثير الاختلاف في القيم
- تحويل البيانات إلى مصفوفات: NumPy لتسهيل إدخالها إلى النموذج

كما تم تقسيم البيانات إلى:

- بيانات تدريب (Training Set)
- بيانات اختبار (Test Set)

وذلك لضمان تقييم عادل للنموذج.

4-6- بناء النموذج (Model Building)

تم اعتماد نموذج (Bi-LSTM (Bidirectional Long Short-Term Memory نظراً لقدرته على تحليل البيانات الزمنية في اتجاهين، مما يسمح بفهم أفضل لتسلسل الحركات.

يتكون النموذج من:

- طبقة إدخال (Input Layer)
- طبقة أو أكثر من Bi-LSTM
- طبقة كثيفة (Dense Layer)
- طبقة إخراج باستخدام Softmax للتصنيف

يعتمد النموذج على دمج المعلومات من الماضي والمستقبل ضمن التسلسل، مما يعزز دقة التنبؤ.

4-7- تدريب النموذج (Model Training)

تم تدريب النموذج باستخدام بيانات التدريب، مع ضبط مجموعة من المعاملات (Hyperparameters) ، مثل:

- عدد العصور (Epochs)
- حجم الدفعة (Batch Size)
- معدل التعلم (Learning Rate)

وتم استخدام خوارزمية تحسين مثل:

- Adam Optimizer

خلال التدريب، تم مراقبة كل من:

- قيمة الخسارة (Loss)
- دقة النموذج (Accuracy)

وذلك لضمان استقرار عملية التعلم.

4-8- تقييم النموذج (Model Evaluation)

تم تقييم النموذج باستخدام بيانات اختبار مستقلة، وذلك لتجنب ظاهرة Overfitting وضمان تعميم النتائج.

تم اعتماد المعايير التالية:

- Accuracy
- Precision
- Recall
- F1-Score

ويُعتبر مقياس **F1-Score** من أهم المعايير في هذا البحث، نظرًا لقدرته على تحقيق توازن بين Precision و Recall ، خاصة في حالة البيانات غير المتوازنة، حيث قد تكون بعض الإشارات ممثلة أكثر من غيرها.

4-9- أدوات التنفيذ

تم تنفيذ النظام باستخدام مجموعة من الأدوات البرمجية، منها:

- لغة Python
- مكتبة TensorFlow / Keras
- مكتبة NumPy
- أدوات استخراج Keypoints

وقد ساهمت هذه الأدوات في تسهيل عملية بناء النموذج وتدريبه.

10-4- خاتمة الفصل

تم في هذا الفصل عرض المنهجية المتبعة في تطوير نظام التعرف على لغة الإشارة، بدءًا من جمع البيانات، مرورًا بمعالجتها، ووصولًا إلى بناء النموذج وتقييمه.

أظهرت المنهجية المعتمدة أهمية استخدام تمثيل فعال للبيانات (Keypoints) مع نموذج زمني مناسب (Bi-LSTM) ، لتحقيق توازن بين الدقة والكفاءة.

سيتم في الفصل التالي عرض نتائج النموذج وتحليل أدائه باستخدام المعايير المذكورة.

الفصل الخامس: نتائج البحث

35	الأدوات المستعملة وأساليب التقييم المتبعة.....
35	الأدوات المستخدمة.....
35	معايير التقييم.....
36	نتائج النموذج المقترح.....
38	مقارنة النتائج.....
38	مقارنة نتائج النماذج المقترحة:.....
39	مقارنة النتائج مع الأعمال السابقة.....
40	خاتمة الفصل.....

5-1- مقدمة

يهدف هذا الفصل إلى عرض نتائج النموذج المقترح وتقييم أدائه باستخدام مجموعة من المعايير المناسبة لطبيعة المسألة. كما يتضمن مقارنة بين أداء النموذج المقترح وبعض النماذج الأخرى، بالإضافة إلى تحليل نقاط القوة والضعف.

تم إجراء عملية التقييم اعتمادًا على بيانات اختبار مستقلة، وذلك لضمان موضوعية النتائج وعدم تأثرها ببيانات التدريب.

5-2- الأدوات المستعملة وأساليب التقييم المتبعة

5-2-1- الأدوات المستخدمة

تم تنفيذ النموذج المقترح باستخدام بيئة برمجية تعتمد على لغة Python ، وذلك نظرًا لما توفره من مكتبات قوية في مجال التعلم العميق ومعالجة البيانات. وقد تم استخدام الأدوات التالية:

- لغة Python لكتابة وتنفيذ جميع مراحل المشروع
- TensorFlow / Keras لبناء نموذج Bi-LSTM وتدريبه
- NumPy لمعالجة البيانات وتحويلها إلى مصفوفات عددية
- OpenCV لمعالجة الفيديو واستخراج الإطارات
- MediaPipe لاستخراج النقاط الرئيسية (Keypoints) لليد والجسم
- Matplotlib لعرض النتائج ورسم المنحنيات

5-2-2- معايير التقييم

تم استخدام مجموعة من المعايير الشائعة في مسائل التصنيف، وهي:

- الدقة: (Accuracy)
- تمثل نسبة التنبؤات الصحيحة إلى إجمالي التنبؤات وتعطى بلعلاقة:

Equation 15: معادلة الدقة

$$(1/5)Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)}$$

- الاستدعاء: (Recall)
- يقيس قدرة النموذج على اكتشاف جميع الحالات الصحيحة وتعطى بلعلاقة:

Equation 16: معادلة الاستدعاء

$$(2/5)Recall = \frac{TP}{(TP + FN)}$$

- الدقة النوعية: (Precision)
- تعكس نسبة التنبؤات الصحيحة من بين التنبؤات الإيجابية وتعطى بلعلاقة:

Equation 17: معادلة الدقة النوعية

$$\text{Precision} = \frac{TP}{(TP + FP)} \quad (3/5)$$

مقياس: F1

وهو المتوسط التوافقي بين Precision و Recall ، ويعطي تقييماً متوازناً للأداء و يعطى بلعلاقة:

Equation 18: مقياس F1-score

$$\text{F1-Score} = 2 * \frac{(\text{Precision} * \text{Recall})}{(\text{Precision} + \text{Recall})} \quad (4/5)$$

تم الاعتماد على مقياس F1-Score بشكل أساسي، نظراً لطبيعة البيانات المستخدمة في هذا البحث، والتي قد تكون غير متوازنة (Imbalanced Data)، حيث لا تظهر جميع الإشارات بنفس التكرار.

في هذه الحالة:

- قد نعطي Accuracy نتائج مضللة
- بينما يوفر F1-Score تقييماً أكثر دقة لأنه يوازن بين Precision و Recall

وبالتالي، يعتبر هذا المقياس الأنسب لتقييم أداء النموذج في هذا النوع من التطبيقات.

3-5- نتائج النموذج المقترح

تم تدريب نموذج Bi-LSTM على بيانات Keypoints ، ومن ثم تقييمه باستخدام بيانات اختبار مستقلة.

النتائج:

- Accuracy: 76%
- Vald Accuracy: 71.9%
- F1-Score: 67.1%
- , و يشير الشكل -8- الى نتائج معايير التقييم هذه




Figure 8: معمارية النموذج المقترح




Figure 9: مخطط التعلم

5-4- مقارنة النتائج

5-4-1- مقارنة نتائج النماذج المقترحة:

لقد قمنا بعمل اربعة تجارب

التجربة الاولى:

نموذج LSTM فقط بدون Augmentation كانت النتائج سيئة

• Train Accuracy=39.2%

• Vald Accuracy=10.6%

التجربة الثانية:

نموذج LSTM مع Augmentation للداتا بلاضافة ل MediaPipe

Point for pose 132

Point for Left Hand 63

Points for Right Hand 63

اعطا النموذج نتائج افضل من قبل حيث حقق:

• Train Accuracy=52.8%

• Vald Accuracy=19.6%

التجربة الثالثة:

نموذج Bi-LSTM مع CNN و Augmentation للداتا زيادة عدد الفيديوهات ل30 فيديو لكل كلاس بلاضافة ل MediaPipe

Point for pose 132

Point for Left Hand 63

Points for Right Hand 63

• Train Accuracy=92.6%

• Vald Accuracy=69.4%

التجربة الرابعة:

نموذج Bi-LSTM مع CNN و Augmentation للدانا زيادة عدد الفيديو هات ل 80 فيديو لكل كلاس بلاضافة ل MediaPipe

Point for pose 66

Point for Left Hand 42

Points for Right Hand 42

Train Accuracy=76% •

Vald Accuracy=71.9% •

تم مقارنة النموذج المقترح مع نموذج LSTM التقليدي:

جدول مقارنة النتائج للنماذج المقترحة Table 2

التجربة	Train Accuracy	Vald Accuracy
الاولى	39.2%	10.6%
الثانية	52.8%	19.6%
الثالثة	92.6%	69.4%
الرابعة	76%	71.9%

تحليل النتائج:

- نموذج Bi-LSTM حقق أداءً أفضل من LSTM
- يعود ذلك إلى قدرته على تحليل التسلسل في اتجاهين
- مما يساعد في فهم الإشارات بشكل أدق

ويعود هذا التحسن إلى قدرة النموذج على الاستفادة من المعلومات المستقبلية بالإضافة إلى المعلومات السابقة.

5-4-2- مقارنة النتائج مع الأعمال السابقة

عند مقارنة النموذج المقترح مع بعض الأعمال السابقة، يمكن ملاحظة ما يلي:

- يحقق النموذج أداءً مقارباً للنماذج الحديثة المعتمدة على التعلم العميق
- يتميز بكفاءة أعلى من حيث استهلاك الموارد مقارنة بالنماذج المعقدة مثل 3D-CNN و Transformers

- يقدم توازنًا جيدًا بين الدقة وسرعة التنفيذ

Table 3: جدول مقارنة نتائج النموذج المقترح مع النماذج السابقة

النماذج المستخدمة	Accuracy	الدراسة
CNN+Bi-LSTM	71.9%	دراستنا
CNN+Detection Transformer	91.3%	الدراسة الاولى
Transformer	89.6%	الدراسة الثانية
Transformer + keypoints	90.4%	الدراسة الثالثة
Multiple Tranformer Encoder	92.1%	الدراسة الرابعة
Video Transformer	93.5%	الدراسة الخامسة
Transformer + 2d/3d Pose	94.2%	الدراسة السادسة
GCN	90.7%	الدراسة السابعة
ResGCN+Attention	91.8%	الدراسة الثامنة

من خلال النتائج التي تم الحصول عليها، يمكن استخلاص عدد من الملاحظات:

نقاط القوة

- قدرة جيدة على تحليل البيانات الزمنية
- أداء مستقر أثناء التدريب والاختبار
- كفاءة في استخدام الموارد الحاسوبية
- بساطة نسبية في البنية مقارنة بالنماذج الحديثة

نقاط الضعف

- يعتمد الأداء بشكل كبير على جودة البيانات المدخلة
- قد يواجه صعوبة في التمييز بين الإشارات المتشابهة
- محدودية في التعامل مع عدد كبير جدًا من الفئات

تحسينات ممكنة

- زيادة حجم البيانات المستخدمة في التدريب
- استخدام تقنيات تحسين مثل Data Augmentation
- دمج النموذج مع تقنيات أحدث مثل Attention Mechanism

5-5- خاتمة الفصل

تم في هذا الفصل عرض نتائج النموذج المقترح وتحليل أدائه باستخدام مجموعة من المعايير المناسبة. كما تمت مقارنة النتائج مع نماذج أخرى ومع بعض الأعمال السابقة، مما أظهر أن النموذج يحقق أداءً جيدًا مع كفاءة مقبولة.

تشير النتائج إلى أن استخدام نموذج Bi-LSTM يمثل خيارًا مناسبًا لمعالجة البيانات الزمنية في تطبيقات التعرف على لغة الإشارة.

سيتم في الفصل التالي عرض الاستنتاجات النهائية للبحث، بالإضافة إلى التحديات التي واجهت العمل والآفاق المستقبلية للتطوير.

الفصل السادس: الخاتمة

43التحديات والآفاق المستقبلية

43التحديات

43الآفاق المستقبلية

6-1- الاستنتاجات

تناول هذا البحث تطوير نظام ذكي للتعرف على لغة الإشارة اعتمادًا على تقنيات التعلم العميق، وذلك بهدف تحسين التواصل مع الأشخاص ذوي الإعاقة السمعية والمساهمة في دمجهم في المجتمع.

تم بناء نموذج يعتمد على Bi-LSTM لمعالجة البيانات الزمنية المستخرجة من النقاط الرئيسية (Keypoints)، حيث أظهر النموذج قدرة جيدة على تحليل تسلسل الحركات والتعرف على الإشارات المختلفة. كما تم تصميم Pipeline متكامل يشمل مراحل معالجة البيانات، التدريب، والتقييم.

أظهرت النتائج أن النموذج المقترح قادر على تحقيق توازن مقبول بين الدقة والكفاءة، حيث استفاد من تحليل البيانات في اتجاهين، مما ساهم في تحسين جودة التنبؤات مقارنة بالنماذج التقليدية.

بشكل عام، يمكن اعتبار هذا العمل خطوة عملية نحو تطوير أنظمة أكثر تطورًا في مجال التعرف على لغة الإشارة.

6-2- التحديات والآفاق المستقبلية

6-2-1- التحديات

واجه هذا البحث عددًا من التحديات، من أبرزها:

- محدودية البيانات المتاحة للتدريب
- تعقيد الإشارات الحركية وتداخلها
- صعوبة التمييز بين بعض الإشارات المتشابهة
- الحاجة إلى موارد حاسوبية مناسبة لتدريب النموذج

6-2-2- الآفاق المستقبلية

يمكن تطوير هذا العمل في عدة اتجاهات مستقبلية، منها:

- استخدام نماذج أكثر تطورًا مثل Transformers
- توسيع قاعدة البيانات لتشمل عددًا أكبر من الإشارات
- دعم لغات إشارة مختلفة
- تطوير تطبيق عملي يعمل في الزمن الحقيقي (Real-Time)
- دمج تقنيات إضافية مثل التعرف على تعابير الوجه

تشير هذه الآفاق إلى أن المجال لا يزال مفتوحًا للتطوير، وأن تحسين الأنظمة الحالية يمكن أن يسهم بشكل كبير في تعزيز التواصل الإنساني باستخدام التكنولوجيا.