



كلية هندسة المعلوماتية

تحويل لغة اشارة انجليزية الى نص

إعداد الطلاب:

محمد زين محف وظ احمد الطيار رنيم عمران

أسماء المشرفين:

د. ماجدة البكور م. فرح فارس

الفهرس:

جدول المصطلحات:

المعنى	الاختصار	الترجمة للعربية	المصطلح التقني
مجال يهدف إلى تعليم الأنظمة من البيانات دون برمجتها صراحة.	ML	تعلم الآلة	Machine Learning
يتعلم من بيانات تحتوي على مدخلات ومخرجات معروفة.	-	التعلم الخاضع للإشراف	Supervised Learning
يكتشف الأنماط بدون مخرجات معروفة.	-	التعلم غير الخاضع للإشراف	Unsupervised Learning
عندما يتعلم النموذج التفاصيل الدقيقة لدرجة تؤثر سلبيًا على الأداء.	-	الإفراط في التعلم	Overfitting
عندما لا يلتقط النموذج الأنماط الأساسية.	-	ضعف التعلم	Underfitting
مرور واحد كامل على مجموعة بيانات التدريب.	-	تكرار التدريب	Epoch
سرعة تعديل النموذج أثناء التدريب.	-	معدل التعلم	Learning Rate
معايير لمدى بعد التنبؤات عن القيم الحقيقية.	-	دالة خسارة	Loss Function
خوارزمية لتقليل دالة الخسارة.	-	المُحسِّن	Optimizer
بنية مستوحاة من الدماغ تُستخدم في التعلم.	NN	الشبكة العصبية	Neural Network
تعلم باستخدام الشبكات العصبية العميقة.	DL	التعلم العميق	Deep Learning

Classification	التصنيف	-	توقع فئة معينة للبيانات.
----------------	---------	---	--------------------------

Regression	الانحدار	-	توقع قيمة عددية مستمرة.
Accuracy	الدقة	-	نسبة التنبؤات الصحيحة إلى المجموع.
Pandas	باندا س لمعالجة البيانات	-	مكتبة برمجية تُستخدم لمعالجة وتحليل البيانات الجدولية
NumBy	الحوسبة العددية	-	مكتبة أساسية للحسابات الرياضية
Matplotlib	مكتبة الرسوم البيانية	-	مكتبة تُستخدم لإنشاء الرسوم والمخططات البيانية
Seaborn	التصوير الإحصائي للبيانات	-	مكتبة مبنية على Matplotlib، تُستخدم لإنشاء رسومات إحصائية متقدمة
Scikit-learn	-	-	مكتبة متخصصة في تعلم الآلة، تُستخدم لبناء نماذج التنبؤ والتصنيف والتجميع، إضافة إلى تقييم أداء النماذج وتحسينها
Support Vector Machine	آلة دعم المتجهات	SVM	خوارزمية من خوارزميات تعلم الآلة تُستخدم للتصنيف والانحدار
Random Forest	الغابة العشوائية	RF	خوارزمية تعلم آلي تعتمد على مجموعة من أشجار القرار،
Decision Tree	شجرة القرار	DT	نموذج تعلم آلي يمثل القرارات على شكل شجرة،
Coefficient of Determination	معامل التحديد	R²	مقياس إحصائي يُستخدم لتقييم أداء نماذج الانحدار

Root Mean Squared Error	الجذر التربيعي لمتوسط مربع الخط أ	RMSE	مقياس يُستخدم لتقييم دقة النماذج التنبؤية،
Standard Deviation	الانحراف المعياري	SD	مقياس لتقلب أو تشتت البيانات حول المتوسط.
Regression	الانحدار	-	تقنية إحصائية تُستخدم لنمذجة العلاقة بين المتغيرات.

Mean Absolute Error	متوسط الخطأ المطلق	MAE	هو مقياس إحصائي يُستخدم لقياس متوسط مقدار الفرق المطلق بين القيم المتوقعة من النموذج والقيم الحقيقية
Mean Squared Error	متوسط مربع الخطأ	MSE	هو مقياس يُحسب من خلال تربيع الفرق بين القيم المتوقعة والحقيقية ثم حساب المتوسط
Precision	الدقة	-	نسبة الإصحاء الصحيحة التي تم تحديدها بشكل صحيح
Recall	معدل الاسترجاع	-	نسبة الإصحاء الصحيحة التي تم تحديدها بشكل صحيح
F1-Score	درجة F1	-	متوسط حسابي بين Precision , Recall يستخدم لتحديد أداء النموذج
Voting Classifier	مصنف التصويت	-	نموذج يجمع تنبؤات عدة نماذج عبر التصويت .
Ensemble Learning	التعلم التجميعي	-	طريقة تجمع نماذج متعددة لتحسين الأداء العام .
Particle Swarm Optimization	خوارزميات السرب	PSO	خوارزمية تحسين مستوحاة من سلوك أسراب الطيور، تبحث عن أفضل حل من خلال تعاون مجموعة من الحلول وتبادل الخبرات بينها.
Long Short-Term Memory	الذاكرة طويلة قصيرة المدى ثنائية الاتجاه	LSTM	نوع مطور من RNN يعالج مشكلة نسيان المعلومات القديمة، مناسب للتسلسل الطويل مثل الجمل الطويلة.

Bidirectional Long Short-Term Memory	الذاكرة طويلة قصيرة المدى	Bi-LSTM	قرأ البيانات من الأمام والخلف معاً لفهم السياق الكامل، يستخدم كثيراً في معالجة اللغة الطبيعية.
Convolutional Neural Networks	الشبكات العصبية الالتفافية	CNN	تستخدم لاستخراج الميزات من الصور والفيديو عبر فلاتر نكتشف الحواف والأشكال، ممتازة للرؤية الحاسوبية.
Recurrent Neural Networks	الشبكات العصبية التكرارية	RNN	تستخدم لمعالجة البيانات المتسلسلة مثل النصوص والصوت لأنها تحتفظ بمعلومات من الخطوات السابقة.
Autoencoder	المُرَمِّز التلقائي	-	شبكة تتعلم تمثيلاً مضغوطاً للبيانات، تستخدم في تقليل الأبعاد واكتشاف الشذوذ.
Multi-Layer Perceptron	الشبكات العصبية متعددة الطبقات	MLP	شبكة عصبية تتكون من عدة طبقات من العصبونات، تستخدم للتصنيف والتنبؤ وحل المشكلات غير الخطية.
Transformers	نماذج المحولات	-	نماذج تعتمد على آلية الانتباه لفهم العلاقات بين الكلمات دفعة واحدة، وتستخدم بكثرة في معالجة اللغة الطبيعية.

ملخص المشروع:

يستخدم الأشخاص الذين يعانون من مشكلات في السمع والنطق لغة الإشارة كوسيلة أساسية للتواصل فيما بينهم ومع الآخرين داخل المجتمع. وتعتمد هذه اللغة على مجموعة من الحركات اليدوية، والإيماءات، وتعبيرات الوجه، ووضعيات الجسد التي تشكل نظاماً لغوياً متكاملًا يعبر عن الكلمات والأفكار. وعلى الرغم من أهمية هذه اللغة، إلا أنها ليست معروفة على نطاق واسع، مما يؤدي إلى فجوة تواصلية تحد من اندماج الصم في الحياة الاجتماعية والمهنية.

ومع التطور السريع في تقنيات الذكاء الاصطناعي والرؤية الحاسوبية، أصبح من الممكن تطوير أنظمة ذكية قادرة على تفسير لغة الإشارة وترجمتها. وتعد أنظمة التعرف على لغة الإشارة (Sign Language Recognition Systems) من أهم تطبيقات التفاعل بين الإنسان والحاسوب، حيث انتقلت من تحليل الصور الثابتة إلى تحليل مقاطع الفيديو المتسلسلة باستخدام تقنيات التعلم العميق (Deep Learning).

وفي هذا السياق، تبرز لغة الإشارة الأمريكية (ASL) كواحدة من أكثر لغات الإشارة دراسة واستخداماً عالمياً. ومع ذلك، يواجه الباحثون تحديات كبيرة في بناء نماذج قادرة على فهم الإشارات بمستوى الكلمات (Word-level) نظراً للتعقيد العالي في الحركات وتداخل الإيماءات.

قاعدة بيانات WLASL-100 المعتمدة: في هذا العمل، تم الاعتماد على نسخة مخصصة من قاعدة بيانات (WLASL (World-Level American Sign Language المتاحة عبر منصة "Kaggle"، وبالتحديد مجموعة الـ 100 فئة (WLASL-100) وتعتبر هذه القاعدة المعيار الذهبي الحالي للأبحاث، حيث تحتوي على مقاطع فيديو واقعية تم جمعها من مصادر متنوعة على الإنترنت لمؤدين مختلفين، مما يزيد من صعوبة المهمة وقيمة النتائج. تضم هذه المجموعة 100 كلمة (فئة) شائعة في لغة الإشارة الأمريكية، مما يوفر بيئة غنية لتدريب النماذج على التعرف على المفردات بدقة.

يساهم هذا العمل في دعم الجهود الرامية إلى تطوير أنظمة ترجمة تلقائية ذكية، مما يساعد على تحسين التواصل بين الأشخاص الصم وبقية أفراد المجتمع، ويعزز من فرص دمجهم في مختلف مجالات الحياة من خلال تقليل الاعتماد على المترجمين البشريين وتوفير حلول تقنية فورية.

Abstract:

People with hearing and speech impairments use sign language as their primary means of communication with each other and with others in their communities. This language relies on a set of hand movements, gestures, facial expressions, and body postures that form a complete linguistic system expressing words and ideas. Despite its importance, sign language is not widely known, leading to a communication gap that limits the social and professional integration of deaf individuals. With the rapid development of artificial intelligence and computer vision technologies, it has become possible to develop intelligent systems capable of interpreting and translating sign language. Sign language recognition systems are among the most important applications of human-computer interaction, having evolved from analyzing still images to analyzing sequential video clips using deep learning techniques. In this context, American Sign Language (ASL) stands out as one of the most studied and used sign languages globally. However, researchers face significant challenges in building models capable of understanding word-level signs due to the high complexity of the movements and the overlap of gestures. The WLASL-100 :Database

In this work, a customized version of the WLASL (World-Level American Sign Language) database available through the Kaggle platform was used, specifically the 100-category set (WLASL-

100). This database is considered the current gold standard for research, as it contains real-life videos collected from various online sources featuring different performers, thus increasing the difficulty of the task and the value of the results. This set includes 100 common words (categories) in American Sign Language, providing a rich environment for training models to accurately recognize vocabulary. This work contributes to efforts to develop intelligent automatic translation systems, which help improve communication between deaf people and the rest of society and enhance their inclusion in various aspects of life by reducing reliance on human interpreters and .providing immediate technological solutions

لمحة عن الدراسات المرجعية:

التوجهات الحديثة في قواعد بيانات وتقنيات التعرف على لغة الإشارة (2025)

تشهد الأبحاث الحالية في عام 2025 طفرة نوعية في تطوير قواعد البيانات والمنهجيات التقنية للتعرف على لغة الإشارة، حيث انتقل التركيز من الصور الثابتة إلى السلاسل الزمنية والبيانات ثلاثية الأبعاد. وتبرز الدراسات التالية كأهم المراجع الحديثة التي تعزز التوجه التقني المعتمد في هذا المشروع:

1. التحول نحو البيانات الديناميكية والسلاسل الزمنية: أظهرت الدراسات الحديثة، مثل دراسة قاعدة بيانات **LSC-54** للغة الإشارة الكولومبية، أهمية تمثيل الإشارات كـ "سلاسل زمنية (Time-Series)" (Data) باستخدام إحداثيات ثلاثية الأبعاد لمفاصل الجسم واليدين. هذا التوجه يدعم استخدام نماذج التعلم العميق المتخصصة في التحليل الزمني مثل **LSTM** و **RNN**، وهو ما تم تطبيقه في مشروعنا الحالي للتعامل مع الطبيعة الحركية لإشارات **WLASL-100**.

2. استخراج الميزات المتقدمة: (MediaPipe Holistic): تعد دراسة **TurkSign446** للغة الإشارة التركية مرجعاً أساسياً في استخدام خوارزمية **MediaPipe Holistic** لاستخراج مفاصل الجسم واليدين والوجه. حيث أثبتت النتائج أن الاعتماد على هذه المعالم الرقمية بدلاً من الصور الخام يحسن دقة النماذج الهجينة التي تجمع بين **CNN** والشبكات المتكررة مثل **GRU** و **Bi-LSTM**. وهذا يؤكد صحة المنهجية المتبعة في هذا المشروع باستخراج 258 ميزة لكل إطار لضمان دقة الوصف الحركي.

3. التعرف على الإشارات المستمرة والبيانات الواقعية: اتجهت أبحاث مثل دراسة **Isharah** للغة الإشارة السعودية نحو "لغة الإشارة المستمرة (Continuous Sign Language)"، حيث تم جمع البيانات في بيئات غير مقيدة باستخدام كاميرات الهواتف الذكية لضمان قدرة النماذج على العمل في ظروف واقعية. هذا التنوع في زوايا التصوير والإضاءة هو ما يهدف مشروعنا لمحاكاته من خلال استخدام مجموعة **WLASL** التي تجمع فيديوهات من مصادر متنوعة عبر الإنترنت.

4. شمولية البيانات وتقليل التحيز: ركزت الدراسات الحديثة الخاصة بإشارات اليد والأبجدية، مثل **SignAlphaSet** ودراسات الكشف عن إشارات اليد باستخدام الذكاء الاصطناعي (2025)، على أهمية تنوع المشاركين من حيث الفئات العمرية وخصائص البشرة لتقليل مشكلة "التحيز" في النماذج. تم اعتماد هذا المبدأ في مشروعنا من خلال تقنيات زيادة البيانات (Data Augmentation) لضمان تعميم النموذج على مختلف المؤدين.

5. النماذج الهجينة وآليات التنبؤ: تتفق معظم الدراسات المرجعية لعام 2025 على أن النماذج التي تدمج بين استخراج الخصائص البصرية والتحليل الزمني (مثل النموذج المستخدم في هذا العمل) تحقق أعلى معدلات الدقة. إن استخدام نماذج مثل **Bi-LSTM** مع آليات الانتباه (Attention) يمثل القمة التقنية التي وصلت إليها الأبحاث الحالية لتجاوز عقبات التشابه بين الإشارات وتداخل الحركات السريعة.

الفصل الاول:

التعريف بلمشروع:

نظام ذكي للتعرف على لغة الإشارة الأمريكية (WLASL-100)

يهدف هذا المشروع إلى تطوير نظام ذكي للتعرف على لغة الإشارة الأمريكية (ASL) بالاعتماد على بيانات فيديو حقيقية مستمدة من مجموعة بيانات **WLASL-100** الشهيرة. يحتوي المشروع على سجلات دقيقة تشمل مقاطع فيديو لمؤدين مختلفين يقومون بأداء 100 كلمة شائعة في لغة الإشارة. يقوم المشروع على تحليل هذه البيانات الزمنية والمكانية بهدف استخراج الأنماط الحركية المتكررة، وبناء نموذج تنبؤي قادر على تحويل الحركات الجسدية والإيماءات اليدوية إلى نصوص مفهومة بدقة عالية .

يعتمد المشروع على بنية هجينة من خوارزميات التعلم العميق (Deep Learning) لما تتمتع به من قدرة فائقة على التعامل مع البيانات المتسلسلة وعالية الأبعاد. تشمل هذه التقنيات ما يلي:

1. **MediaPipe Holistic**: تُستخدم لاستخراج النقاط المرجعية (Keypoints) للجسم واليدين والوجه وتحويلها إلى متجهات رقمية، مما يقلل من تعقيد البيانات الخام ويركز على الحركات الأساسية للإشارة .
2. **Long Short-Term Memory (LSTM)** وتحديدًا النوع ثنائي الاتجاه (**Bidirectional LSTM**)، والذي يتميز بقدرته على فهم السياق الزمني للحركة من بدايتها إلى نهايتها، مما يجعله مثاليًا لتفسير الإشارات التي تعتمد على تتابع زمني معين .
3. **Attention Mechanism (آلية الانتباه)**: (تم دمج هذه الطبقة لتمكين النموذج من التركيز على الإطارات الأكثر أهمية داخل مقطع الفيديو (مثل لحظة اكتمال تشكيل اليد)، مما يقلل من تأثير الحركات العشوائية ويزيد من دقة التصنيف .
4. **الشبكات الالتفافية (CNN)**: تُستخدم في المراحل الأولى لاستخراج الخصائص البصرية من الإطارات وتغذيتها للنموذج الزمني، مما يضمن الحصول على تمثيل دقيق لكل حركة .

يتضمن المشروع أيضاً معالجة متقدمة للبيانات من خلال توحيد أطوال المقاطع الزمنية باستخدام الاستيفاء (Interpolation) والحشو (Padding)، والتعامل مع مشكلة عدم توازن الفئات (Class Imbalance) عبر تقنيات زيادة البيانات (Data Augmentation) مثل إضافة الضجيج العشوائي وتغيير مقاييس الحركة . كما تم تقسيم البيانات إلى مجموعات تدريب واختبار لتقييم أداء النموذج بشكل موضوعي باستخدام مقاييس الدقة (Accuracy) ومصفوفة الارتباك (Confusion Matrix).

نسعى من خلال هذا المشروع إلى تقديم أداة فعالة يمكن دمجها في تطبيقات التواصل الفوري وأنظمة المساعدة الذكية، بحيث يتمكن المستخدمون الصم من التواصل مع عامة الناس بسهولة ويسر، مما يقلل من الفجوة التواصلية ويعزز من فرص دمجهم في المجتمع. إضافة إلى ذلك، يهدف المشروع إلى دعم الأبحاث الأكاديمية في مجال التفاعل بين الإنسان والحاسوب (HCI) وتطوير أنظمة ترجمة آلية أكثر كفاءة.

كما يهدف بشكل عام إلى تقديم نموذج أكاديمي وعملي قائم على التعلم العميق يمكن الاعتماد عليه في مجال التعرف على اللغات الإشارية، مع إمكانية تطويره مستقبلاً للتعامل مع مجموعات بيانات أوسع وأكثر تعقيداً تشمل جملاً كاملة، وبذلك يشكل خطوة مهمة نحو تطوير أنظمة تواصل أكثر ذكاءً وشمولية.

الأهداف الرئيسية للمشروع:

الهدف الرئيسي من المشروع هو التطوير المسبق لأنظمة ذكية قادرة على فهم وترجمة لغة الإشارة الأمريكية بدقة عالية، بما يضمن توفير وسيلة تواصل كفؤة وآمنة ومستدامة لمجتمع الصم والبكم.

- **كسر حواجز التواصل:** تحويل إيماءات وحركات لغة الإشارة إلى نصوص أو كلام منطوق في الوقت الحقيقي، مما يسهل التفاعل اليومي بين مستخدمي لغة الإشارة وعامة المجتمع.
- **تطوير أدوات تعليمية وتقنية:** توفير نظام يمكن دمج في المنصات التعليمية لمساعدة الراغبين في تعلم لغة الإشارة، أو استخدامه كواجهة تحكم ذكية تعتمد على الإيماءات في أنظمة التفاعل بين الإنسان والحاسوب .
- **الوصول إلى استقلالية أكبر:** تمكين الأشخاص الصم من الوصول إلى الخدمات الأساسية (مثل الصحة والتعليم والطوارئ) دون الحاجة الدائمة لمترجم بشري، مما يعزز من خصوصيتهم واستقلاليتهم.
- **دعم التحول الرقمي الشامل:** المساهمة في بناء بنية تحتية رقمية تدعم التنوع والشمول، من خلال توفير خوارزميات برمجية قابلة للدمج في الهواتف الذكية وكاميرات الحواسيب لدعم التطبيقات الواقعية .

أهمية المشروع:

تنبع أهميته من الحاجة المتزايدة إلى أنظمة تفاعل بين الإنسان والحاسوب (HCI) قادرة على تحليل الحركات البشرية الحقيقية وتوفير ترجمة فورية تساعد في تحسين جودة حياة الأشخاص الصم . يسهم المشروع في دعم المستخدمين عبر تمكينهم من التواصل بسلاسة في البيئات العامة، مما يقلل من العزلة الاجتماعية ويحسن من كفاءة التفاعل مع الخدمات التعليمية والصحية .

كما يقدم المشروع قيمة كبيرة للباحثين والمطورين في مجال الذكاء الاصطناعي، إذ يساعد على اتخاذ قرارات تقنية مبنية على تحليل علمي دقيق لتسلسل الحركات عبر الزمن باستخدام خوارزميات التعلم العميق . وتتمثل أهميته في الآتي :

- **تحسين النمذجة الحركية:** تطوير أنظمة قادرة على استيعاب الأنماط المعقدة للغة الإشارة وفقاً للبيانات الديناميكية المستخرجة من الجسم واليدين والوجه .
- **الدقة والفاعلية:** الدور المحوري في الحد من الأخطاء اللغوية في الترجمة الآلية عبر استخدام تقنيات MediaPipe Holistic لضمان دقة المعالم المستخرجة .

- القيمة العلمية والأكاديمية: توفير دراسة مقارنة وتقييم شامل لأداء نماذج LSTM و Bi-LSTM و Attention Mechanisms في التعرف على الإشارات .
- التحول الرقمي والشمولية: يشكل خطوة مهمة نحو استخدام الذكاء الاصطناعي في دعم التنوع البشري، ويسهم في تطوير تطبيقات الهواتف الذكية التي تعمل ك مترجم شخصي فوري .
- تحسين الاستجابة للطوارئ: تبرز أهميته في تمكين الصم من التواصل السريع مع خدمات الإسعاف أو الشرطة في حالات الضرورة دون وسيط بشري.
- بناء قواعد بيانات قابلة للتوسع: يمثل المشروع قاعدة يمكن البناء عليها لتطوير نماذج تدعم لغات إشارة محلية أخرى، مما يعزز مفهوم المدن الذكية الشاملة للجميع .

وبشكل عام، فإن أهمية المشروع تتجلى في مساهمته العلمية والعملية في تحويل التكنولوجيا إلى أداة لتمكين الإنسان وتحقيق تواصل أكثر أماناً وسلاسة وكفاءة بين جميع فئات المجتمع.

الفصل الثاني:

الدراسات المرجعية:

الدراسة الأولى: قاعدة بيانات LSC-54 للغة الإشارة الكولومبية(2025)

الرابط:

<https://www.sciencedirect.com/science/article/pii/S2352340925008662>

تهدف هذه الدراسة إلى تطوير قاعدة بيانات جديدة للغة الإشارة الكولومبية (Colombian Sign Language) من أجل دعم تطوير تطبيقات تعليمية وأنظمة للتعرف الآلي على الإشارات باستخدام تقنيات الرؤية الحاسوبية. وتأتي هذه الدراسة استجابة للحاجة المتزايدة إلى أدوات تكنولوجية تساعد مجتمع الصم على التواصل والتعلم في ظل محدودية الموارد التعليمية الخاصة بلغة الإشارة في العديد من الدول.

تعتمد قاعدة البيانات المقترحة على تمثيل الإشارات باستخدام بيانات ثلاثية الأبعاد لمفاصل الجسم واليدين والوجه، حيث تم استخدام تقنيات تتبع المفاصل لاستخراج إحداثيات ثلاثية الأبعاد لحركة اليد والجسم أثناء أداء الإشارة. وتشمل قاعدة البيانات مجموعة من الإشارات التي تغطي مجالات مختلفة مثل الألوان والعبارات الاجتماعية والأرقام.

وتتميز هذه القاعدة بأنها تعتمد على سلاسل زمنية (Time-Series Data) ، مما يسمح باستخدام نماذج التعلم العميق المتخصصة في تحليل البيانات الزمنية.

النماذج المستخدمة:

- LSTM
- RNN

GRU •

معايير التقييم:

Accuracy •

Precision •

Recall •

F1-Score •

الدراسة الثانية: قاعدة بيانات للكشف عن إشارات اليد باستخدام الذكاء الاصطناعي (2025)

الرابط:

<https://www.sciencedirect.com/science/article/pii/S2352340925004330>

تركز هذه الدراسة على إنشاء قاعدة بيانات كبيرة لإشارات اليد يمكن استخدامها لتطوير أنظمة التعرف على لغة الإشارة باستخدام تقنيات التعلم العميق، وخاصة الشبكات العصبية الالتفافية (CNN)

تتكون قاعدة البيانات من حوالي 26,000 صورة لإشارات اليد تمثل حروف الأبجدية، وقد تم التقاطها في بيئة تصوير مضبوطة لتحسين جودة البيانات.

النماذج المستخدمة:

CNN •

MobileNet •

ResNet •

معايير التقييم:

Accuracy •

Precision •

Recall •

F1-Score •

Confusion Matrix •

الدراسة الثالثة: قاعدة بيانات Isharah للغة الإشارة السعودية المستمرة (2025)

الرابط:

<https://arxiv.org/abs/2506.03615>

تقدم هذه الدراسة قاعدة بيانات كبيرة للغة الإشارة السعودية المستمرة، والتي تدعم التعرف على الجمل الكاملة بدلاً من الإشارات المنفصلة.

تتكون القاعدة من أكثر من 30,000 فيديو تم تسجيلها في بيئات واقعية، وتحتوي على تعليقات لغوية وترجمات عربية.

النماذج المستخدمة:

- CNN + LSTM
- Transformer-based models
- Bi-LSTM

معايير التقييم:

- Word Recognition Accuracy
- Precision
- Recall
- F1-Score

الدراسة الرابعة: قاعدة بيانات TurkSign446 للغة الإشارة التركية (2025)

الرابط:

<https://zenodo.org/records/17267294>

تهدف هذه الدراسة إلى تطوير قاعدة بيانات كبيرة للغة الإشارة التركية تضم 446 كلمة مختلفة، تشمل إشارات ثابتة وديناميكية.

تم استخراج خصائص الحركة باستخدام MediaPipe ، كما تم اختبار عدة نماذج تعلم عميق.

النماذج المستخدمة:

- CNN
- LSTM

- GRU
- Bi-LSTM
- (CNN + LSTM نموذج هجين)

معايير التقييم:

- Accuracy
- Precision
- Recall
- F1-Score
- Confusion Matrix

الدراسة الخامسة: قاعدة بيانات SignAlphaSet للغة الإشارة الأمريكية (2025)

الرابط:

<https://data.mendeley.com/datasets/8fmvr9m98w>

تقدم هذه الدراسة قاعدة بيانات لإشارات الأبجدية في لغة الإشارة الأمريكية، وتحتوي على صور وفيديوهات لإشارات الحروف.

النماذج المستخدمة:

- CNN
- LSTM
- CNN + LSTM

معايير التقييم:

- Accuracy
 - Precision
 - Recall
 - F1-Score
-

خلاصة الدراسات السابقة

من خلال مراجعة الدراسات السابقة يتضح أن معظم الأبحاث الحديثة في مجال التعرف على لغة الإشارة تركز على إنشاء قواعد بيانات كبيرة ومتنوعة لدعم تدريب نماذج التعلم العميق. وقد اعتمدت هذه الدراسات على مجموعة من النماذج مثل:

- الشبكات العصبية الالتفافية (CNN)
- الشبكات المتكررة (LSTM)، GRU، RNN
- النماذج الهجينة (CNN + LSTM)
- نماذج Transformer الحديثة

كما استخدمت هذه الدراسات مجموعة من معايير التقييم القياسية، مثل:

- Accuracy
- Precision
- Recall
- F1-Score

وفي بعض الحالات تم استخدام **Word Recognition Accuracy** عند التعامل مع الإشارات المستمرة.

وتشير هذه الدراسات إلى أن توفر قواعد بيانات متنوعة وواقعية يمثل عاملاً أساسياً في تحسين أداء أنظمة التعرف على لغة الإشارة. وعلى الرغم من هذا التقدم، فإن لغات الإشارة في العالم العربي ما زالت بحاجة إلى مزيد من الأبحاث وقواعد البيانات المتخصصة، وهو ما يبرز أهمية تطوير أنظمة للتعرف على لغة الإشارة العربية واليمنية باستخدام تقنيات التعلم العميق.

الفصل الثالث:

النماذج المستخدمة وبنيتها:

قمنا بالاعتماد على نموذج **Bidirectional Long Short-Term Memory (Bi-LSTM)**، نظرًا لقدرته العالية على تحليل الأنماط الزمنية وفهم العلاقات بين عناصر السلسلة.

تُعد البيانات المستخدمة في هذا النوع من التطبيقات (مثل بيانات الإشارات أو الفيديو) بيانات زمنية متسلسلة، حيث تعتمد كل قيمة على القيم السابقة واللاحقة، مما يجعل استخدام النماذج التقليدية غير كافٍ. لذلك تم اختيار نموذج Bi-LSTM لقدرته على التعامل مع هذا النوع من البيانات بكفاءة عالية.

يُعتبر نموذج **Bi-LSTM** تطويرًا لنموذج **LSTM** التقليدي، والذي بدوره يُعد تحسينًا للشبكات العصبية المتكررة (RNN)، حيث تم تصميمه للتغلب على مشكلة تلاشي التدرج (Vanishing Gradient) والقدرة على الاحتفاظ بالمعلومات لفترات زمنية طويلة.

آلية عمل LSTM

يتكون نموذج LSTM من وحدات ذاكرة تحتوي على ثلاث بوابات رئيسية:

- **بوابة النسيان (Forget Gate):** مسؤولة عن تحديد المعلومات التي يجب حذفها من الحالة السابقة.
- **بوابة الإدخال (Input Gate):** تحدد المعلومات الجديدة التي سيتم إضافتها إلى الذاكرة.
- **بوابة الإخراج (Output Gate):** تتحكم في المعلومات التي سيتم تمريرها إلى الخطوة التالية.

تسمح هذه البنية للنموذج بالاحتفاظ بالمعلومات المهمة وتجاهل المعلومات غير الضرورية، مما يجعله مناسبًا لتحليل البيانات الزمنية.

يقوم نموذج **Bi-LSTM** بمعالجة البيانات في اتجاهين مختلفين:

- **الاتجاه الأمامي (Forward):** من بداية السلسلة إلى نهايتها
- **الاتجاه العكسي (Backward):** من نهاية السلسلة إلى بدايتها

ثم يتم دمج ناتج الاتجاهين للحصول على تمثيل أكثر شمولاً للبيانات.

وهذا يعني أن النموذج لا يعتمد فقط على المعلومات السابقة، بل يستفيد أيضًا من المعلومات اللاحقة، مما يساعده على فهم السياق الكامل بشكل أفضل.

الفرق بين LSTM و Bi-LSTM

العنصر	LSTM	Bi-LSTM
اتجاهان (أمامي + عكسي)	اتجاه واحد	اتجاه المعالجة
الماضي والمستقبل	الماضي فقط	السياق المستخدم
أفضل في البيانات التسلسلية	جيد	الأداء
أعلى	أقل	التعقيد الحسابي
أعلى	أقل نسبيًا	الدقة

يتميز نموذج Bi-LSTM بعدة خصائص تجعله مناسبًا ، من أهمها:

- القدرة على تحليل البيانات الزمنية المعقدة
- فهم العلاقات بين عناصر السلسلة بشكل ثنائي الاتجاه
- تحسين دقة التنبؤ مقارنة بالنماذج أحادية الاتجاه
- تقليل فقدان المعلومات المهمة عبر الزمن

وبالتالي، فإن استخدام هذا النموذج يساهم في تحسين أداء النظام في التعرف على الأنماط الديناميكية، خاصة في التطبيقات التي تعتمد على تسلسل الحركات.

تم الاعتماد على نموذج **Bi-LSTM** نظرًا لقدرته العالية على معالجة البيانات التسلسلية وفهم السياق الكامل لها. وقد ساهم هذا النموذج في تحسين دقة النظام من خلال الاستفادة من المعلومات السابقة واللاحقة في آن واحد، مما يجعله خيارًا مناسبًا لتطبيقات التعرف على الأنماط الزمنية.